

Relatório Técnico — Análise do Funil de Sourcing

CloudWalk · Technical Challenge, Atração e Seleção

Alayne Victoria · Dataset fictício (mock_sourcing_dataset.xlsx) · 601 candidatos, jan–jun/2025

Este relatório responde ao case — funil de conversão, sinais de avanço, quando insistir, quando não, e padrões entre canais, recrutadores e perfis — e também mostra parte do raciocínio por trás das conclusões, incluindo os pontos em que a primeira hipótese não se confirmou. Repositório completo (código, dados, notebook, dashboard): github.com/alaynevictoria/cloudwalk-case. Dashboard interativo: alaynevictoria.github.io/cloudwalk-case/dashboard/.

1. Como abordei este case

Com dois dias de prazo, a primeira decisão foi de prioridade, não técnica: estruturei a análise em três camadas, na ordem em que um(a) recrutador(a) tomaria decisão no dia a dia — **funil quantitativo** (onde se perde em cada etapa), **cortes de conversão** (canal, recrutador, senioridade, pra separar variação estrutural de variação de processo), e **sinal qualitativo via IA** (testar se a nota do recrutador ajuda a prever contratação, em vez de assumir que ajuda).

Provocação: antes de abrir a planilha, eu esperava que o gargalo principal fosse técnico — gente reprovando em teste ou entrevista. Errei: o maior degrau de perda do funil inteiro acontece antes de qualquer avaliação (seção 8). Isso mudou o eixo de toda a análise, de "quem reprovamos" para "quem nunca chega a ser avaliado".

Três decisões estruturais

- **Métrica central: taxa de contratação por grupo**, não taxa de avanço por etapa isolada — evita otimizar uma etapa às custas do resultado final.
- **Heurística explicável em vez de modelo de ML caixa-preta** — com 601 linhas, um modelo estatístico teria variância alta e seria difícil de defender numa decisão sobre uma pessoa real.
- **Dados de recrutador sem ranking** — detalhado na seção 4.

2. A planilha antes da análise

mock_sourcing_dataset.xlsx tem 601 linhas e 35 colunas: origem (source_channel, recruiter, sourced_date), marcos booleanos de cada etapa (response_received, screening_pass, interview1_pass, test_taken, offer_sent, hired), três notas objetivas (technical_test_score, behavior_score, manager_score), duas métricas de tempo (response_time_days, stage_duration_days), e um campo de texto livre (recruiter_notes). Antes de calcular qualquer coisa, rodei uma checagem de nulos, distribuição categórica, e contagem de valores únicos por coluna.

Provocação: eu assumi que recruiter_notes fosse texto livre único por candidato. Não é — são apenas 11 frases distintas repetidas entre as 601 linhas. Essa descoberta, feita nos primeiros minutos, mudou minha estratégia de IA na seção 6: classificar 11 templates uma vez, em vez de rodar um classificador linha a linha (redundante e sem necessidade).

4. Canais, recrutadores, e uma decisão consciente

Cruzando source_channel com hired: **Github** converte 11,0%, quase o dobro de **Indicação** (4,7%) — contraintuitivo, já que Indicação costuma ser tratado como canal "premium". Volume de candidatos gerados não é sinônimo de qualidade de conversão.

Canal	Candidatos	Contratações	Taxa
Github	73	8	11,0%
Inbound	69	7	10,1%
Hunting	75	7	9,3%
Banco de Talentos	68	6	8,8%
LinkedIn	81	7	8,6%
...			
Indicação	64	3	4,7%

Cruzando recruiter com hired, a variação entre recrutadores (3,9% a 15,3%, quase 3,9x) é **maior** do que entre canais, com volume comparável entre as pessoas (75 a 121 candidatos cada) — o que descarta "pegou vagas mais fáceis" como explicação isolada.

Recrutador(a)	Candidatos	Contratações	Taxa
Ana	75	10	13,3%
Bruno	98	15	15,3%
Carla	101	9	8,9%
Diego	103	5	4,9%
Fernanda	103	4	3,9%
Gustavo	121	6	5,0%

A tabela está em ordem alfabética, de propósito. É tentador transformar isso num ranking e recomendar "replicar a prática dos melhores" — decidi não fazer isso. Com background em People e L&D, uma coisa que aprendi (e que trago pra qualquer time de dados que eu integre) é que expor publicamente uma métrica individual sensível muda o comportamento das pessoas de um jeito que raramente é o desejado: cria ansiedade de desempenho, incentiva otimizar a métrica em vez da causa raiz, e corrói a segurança psicológica necessária pra admitir "não sei fazer isso tão bem quanto poderia". Mantive os números — omitir seria pior — mas troquei a moldura: ordem alfabética em vez de ranking, e a recomendação (seção 9) fala em comunidade de prática e shadowing, não em "replicar o playbook do topo". Essa mesma lógica está aplicada, de forma idêntica, na seção "Aprendizagem entre pares" do dashboard.

6. IA aplicada, em profundidade

6.1 — Classificação estruturada das notas de recrutador

Como a seção 2 mostrou, recruiter_notes tem só 11 frases distintas entre 601 candidatos. Usei o Claude (Anthropic) pra ler cada uma e classificar em dois eixos: um **tema** (do que a nota fala) e um **sinal** — positivo, risco, ou misto — pra chance de avanço. O prompt pede saída em JSON estruturado (não texto livre) pra ser determinístico o bastante pra alimentar o resto da análise sem parsing manual. O código real, pronto pra API de verdade, está em notebooks/ai_note_classifier.py no repositório.

Nota original (texto real da planilha)	Sinal	Por quê
"Boa comunicação e resposta rápida."	Positivo	indica engajamento
"Baixa responsividade nas etapas iniciais."	Risco	indica possível desistência
"Experiência sólida, mas expectativa salarial alta."	Misto	parte positiva + parte de atrito

Sinal	Candidatos	Taxa de contratação
Misto	57	14,0%
Risco	138	8,0%
Positivo	406	7,4%

Achado mais importante desta seção: o sinal classificado quase não separa quem é contratado — "risco" converte 8,0%, "positivo" converte 7,4%, diferença dentro do ruído estatístico esperado. "Misto" (majoritariamente sobre salário) converte mais (14,0%) — objeção salarial, sozinha, não deveria ser motivo de descarte automático. Eu poderia ter parado na classificação e apresentado isso como um sinal útil; o valor real de testar uma hipótese com dados é poder descobrir que ela está errada, e reportar isso. Por isso o Candidate Advisor dá peso zero a esse sinal — decidi que ser data-driven aqui significa não forçar uma correlação que não existe.

6.2 — O Candidate Advisor: duas camadas, dois propósitos

Usei o Claude como parceiro de raciocínio ao longo de todo o projeto — não só como classificador. Isso levou à peça de engenharia mais ambiciosa do case: o **Candidate Advisor**, no dashboard, que responde "quando vale insistir com um candidato" com uma arquitetura de duas camadas:

- **Determinística** — sempre ativa, sem internet nem chave de API. Um motor de regras calcula um índice de 0 a 10 a partir de canal, recrutador, senioridade, os três scores, tempo de resposta e sinal da nota, com peso explícito por fator: scores e velocidade pesam mais (são os sinais reais, seção 8), a nota qualitativa pesa zero.
- **IA generativa opcional** — chat que usa a própria chave de API do usuário e os dados agregados do dashboard como contexto, para perguntas em linguagem natural.

Por que duas camadas em vez de só a mais impressionante? Uma demo ao vivo não pode depender de uma chave de API funcionando na hora. A camada determinística garante que a ferramenta funciona de qualquer jeito; a de IA é um complemento, não uma dependência — prefiro entregar algo robusto com um bônus opcional a algo vistoso que pode falhar na hora que mais importa.

8. Principais insights

O funil, em números

Etapas	Candidatos	% do total
Sourced	601	100,0%
Respondeu	408	67,9%
Screening OK	308	51,2%
Entrevista OK	234	38,9%
Teste realizado	201	33,4%
Oferta enviada	62	10,3%
Contratado	49	8,2%

O maior degrau de perda é o primeiro: 193 candidatos (32,1%) nunca respondem ao primeiro contato (response_received), antes de qualquer avaliação técnica. Contratados passam ~3,5x mais tempo no funil (stage_duration_days) — processos rápidos tendem a ser descarte rápido, não eficiência.

Scores: o que diferencia quem é contratado

Score (0–100)	Contratados	Não contratados
Score técnico	82,4	72,9
Score comportamental	80,1	74,0
Score do gestor	80,9	73,1

Os três scores diferenciam quem é contratado, não só o técnico — um filtro só por nota técnica descarta sinal comportamental e de gestor relevante.

Resumo, ligado à coluna de origem

#	Insight	Coluna(s)
1	32,1% nunca respondem ao 1º contato	response_received
2	Recrutadores variam 3,9x, mais que canais	recruiter × hired
3	Os três scores diferenciam contratados — não só o técnico	*_score × hired
4	Contratados passam ~3,5x mais tempo no funil	stage_duration_days
5	Sinal de IA sobre a nota tem baixo poder preditivo (achado negativo)	recruiter_notes × hired

Nota de cautela: algumas comparações usam amostras pequenas (recrutadores: 75 a 121 candidatos cada). Diferenças de poucos pontos percentuais devem ser lidas como direção, não certeza estatística.

9. Recomendações práticas

- 1. Redistribuir esforço de sourcing por conversão, não por volume** — Github e Inbound convertem quase o dobro de Indicação e Evento.
- 2. Abrir espaço para troca de prática entre recrutadores** — Shadowing em pares ou comunidade de prática mensal — não avaliação de desempenho individual.
- 3. Atacar o gargalo de resposta inicial** — 32% nunca respondem ao 1º contato — maior perda do funil. Testar cadência de follow-up nos primeiros 3 dias.
- 4. Usar os três scores, não só o técnico, para priorizar candidatos** — Comportamental e gestor têm gap parecido ao técnico entre contratados e não contratados.
- 5. Não usar a nota qualitativa como filtro isolado** — O sinal é fraco (seção 6). Priorizar candidatos ativos por score objetivo + velocidade de resposta.

11. Uma nota para quem vai trabalhar comigo

Se formos trabalhar juntos, é mais ou menos assim que eu funciono: gosto de entender o dado antes de montar a ferramenta, prefiro uma explicação honesta e um pouco mais fraca a uma bonita e inflada, e levo a sério a diferença entre expor uma métrica de um jeito que ajuda alguém a crescer e expor ela de um jeito que só mede. Espero que isso apareça tanto no dashboard quanto neste documento. Fico à disposição para aprofundar qualquer ponto na conversa técnica.